## Import Libraries and Load Data

```
#general packages for data manipulation
import pandas as pd
#visualizations
import matplotlib.pyplot as plt
import seaborn as sns
%matplotlib inline
#consistent sized plot
from pylab import rcParams
rcParams['figure.figsize']=12,5
rcParams['axes.labelsize']=12
rcParams['xtick.labelsize']=12
rcParams['ytick.labelsize']=12
#handle the warnings in the code
import warnings
warnings.filterwarnings(action='ignore',category=DeprecationWarning)
warnings.filterwarnings(action='ignore', category=FutureWarning)
#text preprocessing libraries
from nltk.corpus import stopwords
from nltk.tokenize import WordPunctTokenizer
#import texthero
#import texthero as hero
#regular expressions
import re
#display pandas dataframe columns
pd.options.display.max_columns = None
```

### load csv file as pandas dataframe

```
data = pd.read csv(r'C:\VSCode\NLP4B Football\Own model\model
creation\complete dataset.csv')
#drop the first column because it is not necessary
print(data.head())
print(data.shape)
#copy to a new dataframe
df = data.copy()
# convert comment column to string
df['comment'] = df['comment'].astype(str)
                                                             label
                                             comment
                                                     source
O As a woman you shouldn't complain about cleani...
                                                     kaggle
                                                                 0
1 boy dats cold...tyga dwn bad for cuffin dat ho...
                                                     kaggle
                                                                 1
2 Dawg!!!! You ever fuck a bitch and she start t...
                                                                 1
                                                    kaggle
                                                                 1
  The shit you hear about me might be true or it... kaggle
```

```
4 The shit just blows me..claim you so faithful ... kaggle 1 (3862, 3)
```

# **Text Cleaning**

Convert emojis to text

```
import emoji

def convert_emojis_to_word(comment):
    '''Function to convert emojis to words'''
    # Convert emojis to text
    comment_with_emojis = emoji.demojize(comment)
    return comment_with_emojis

# Apply the function to the comment column
df['comment'] = df['comment'].apply(convert_emojis_to_word)

# print row 663 to see the result
print(df['comment'].iloc[663])
england is t=not aawys the best but atleast they
tried:smiling_face_with_tear::smiling_face_with_tear::smiling_face_with
h_tear::smiling_face_with_tear::loudly_crying_face::loudly_crying_face
::loudly_crying_face:
```

Find things to remove and how often they appear

```
# Function to check for pattern
def check_for_pattern(regex, dataframe, column name):
    '''Function to check for how often a pattern appears in a
dataframe column and returns a list of all the items found'''
    pattern = re.compile(regex)
    result = []
    for i in range(len(dataframe[column name])):
        phrase = (re.findall(pattern, str(dataframe[column name][i])))
# Convert column values to string
        if phrase != []:
            result.append(phrase[0])
    print("Total items found:", len(result), result)
    return result
# Check for user handles
user handles = check for pattern(r'@[\w]*', df, 'comment')
# Check for hashtags
hashtags = check for pattern(r'#[\w]*', df, 'comment')
```

```
# Check for URLs
urls = check for pattern(r'https?://[A-Za-z0-9./]+', df, 'comment')
# Check for punctuations
punctuations = check for pattern(r'[^\w\s]', df, 'comment')
# Check for numbers 18, 88, 1312
numbers = check for pattern(r'18|88|1312', df, 'comment')
#print rows with numbers 18, 88, 1312, show only the comment column
and show the whole comment
print(numbers)
# --> no need to worry
Total items found: 5 ['@soccerboy 04', '@bluprint 4', '@KingCuh',
'@WestYourMajesty', '@']
Total items found: 54 ['#Shots', '#2MW', '#HappyHumpDay',
'#Eaglesnation', '#EarlyChristmas', '#CowboysNation', '#TehGodClan',
'#Yankees', '#FreeMoneyMelle', '#oomf', '#scally', '#fixed',
'#KingOfTheHill', '#UCFPINKPARTY', '#bum', '#hoesaintloyal', '#real',
'#Pisces', '#GerrysHalloweenParty', '#MTVHottest', '#Yankees',
'#ProtectTheAnimals', '#Damn', '#', '#blondeproblems', '#scally',
'#History', '#frenchscally', '#YoureNotMyType', '#shitmybosssays',
'#shitallysays', '#FreshRhymes', '#128514', '#JT2020Tour',
'#50centmovie', '#ThankYouPaulForConfirmingLarry', '#NottingHill',
'#8230', '#233', '#8230', '#RIPTALLT', '#65292', '#Tupac', '#afterearth', '#SNL', '#hoes', '#ShitFahdSays', '#redskins', '#1', '#r', '#BAH', '#WHAT', '#5', '#Well']
Total items found: 2 ['https://x.com/dfb',
'https://youtu.be/8dIQ56YACvE']
'.',
               '#'
                                                        111
                                                              11 11 11
                           '#'
1111
                                            `#`,
                                                   .,.
                                                        11 11 11
                                                                         1 11 1
                                                   '?'
"""
                                      """
                                             ...,
                                                              """
                                                        '!',
                                                   1 11 1
                                                              1111
                                """, """,
                                           11 1 11
                                                        1 1
                                                   1.11.1
                                             11 TH
                                                   1 11 1
                                    ', '.',
, '?'
                                                                         11 1 11
                               ', ','
                                          , '?'
                                                        ...,
                                                   1 11 1
                                                                   1 11 1
                                                                         . . .
          1 11 1
                                                   . . . . ^
                                                        11 11 11
                                                                   1.11.1
                                             171
                                                        "'", '/', '!',
'.', '"'
                                                        ...,
                                                , '%',
                                                   '@'
                                             ....
                                                  11 1 11
                                                        1 11 1
                                                                         1 11 1
                                             '.'
                                                        1111
     1 11 1
                                                  . . . . . .
                                                                   11 1 11
                                                                         1 11 1
     1 11 1
                                                   1 11 1
                                                        1 11 1
1 11 1
        , ' ' '
                                                        1 1
                                                  ....
                                                                   1 11 1
                                           1.,
                                                              : ,
    1 11 1
                                                        11 11 11
                                                  1 11 1
                                           1111
                                                  1111
                                                        '?',
                                                             111
                     , , , ,
          '!',
                                                        '!',
```

"'". '?'. "'".		1 1 11 11	1 1 1 1	1 11 1 1 11 1	1 11 1 1 11 1
, , , ,	, ,	, , , ,	, , , , ,	, ,	, ,
,,,	,,	<i>'</i> ,,,,		,	
,,,	,,	, '"', '"',	,,	,,	,,
1 11 1 1 1 1 1 1 1 1	101 101 101	1 11 1 1 11 1	101 101	1 11 1 1 11 1	101 101
, , ,	, ,	, , ,	, ,	, ,	, ,
		. '"'. '"'.		'''', '''',	1 11 1 1 1 1 1 1
		<i>'</i> ''			
,,,	,,	,,,	,,	,,	,
	101 101 101	1 11 1 1 11 1	101 101	1 11 1 1 11 1	101 101
, , , , , ,	<b>' '</b>	<i>'</i> ''	· ' · '	· ' · '	· , · ,
111, 111, 111,	1111, 1111, 1111	, , , , , ,		'"', '"',	1111 1111
		´ ıпı´ ıпı´			
, , ,	, ,	, , ,	, ,	, ,	, ,
		1111 1111	101 101	1 11 1 1 11 1	1 11 1 1 1 1 1
,,,		<i>,</i> ,,,,,,,,,,,,,,,,,,,,,,,,,,,,,,,,,,,	, , , , , , , , , , , , , , , , , , ,	,	
,,,	,,	, '"', '"',	,,	,,	,,
1 11 1 1 1 1 1 1 1 1	101 101 101	1111 1111	101 101	1 11 1 1 11 1	1 11 1 1 11 1
, , ,	, ,	, , ,	, ,	, ,	, ,
		. '"'. '"'.			1 11 1 1 1 1 1 1
,,,		´ ıпı´ ıпı´		,	
, , , ,	, , ,	, , , , , ,	, ,	, , ,	, , ,
1 11 1 1 1 1 1 1 1 1		101 101	101 101	1 11 1 1 11 1	1 11 1 1 11 1
		<i>,</i> , , , ,	, , ,	, , ,	,
111, 111, 111,	, , ,	, , , , , ,	. '"', ':',	':', '.',	"'", '-',
de el		´ 171´ 11111´	1 1 111		1 1 1 1 1 1
. , . , . ,	, . , .	, , ,	• • • •	• , ,	. , . ,
111. 1.1. 1.1.	1.1. 11. 1:1	. ':'. '.'.		""", """,	1:1. 1.1.
1.1 1111 1.1	1,1, 1,1, 1,1	, , , , , ,	, , ,	,	121 1/1
':' <i>,</i> "'", ':',	, , , , , ; ;	, ':', '.',		':', ':',	'?', '/',
	11 11 1 1 1 1	1,1 1 1	<u> </u>	1 1 1,1	171 1111
. , , ,	, , , ,	, , , , ,	· · · · · · · · · · · · · · · · · · ·	. , . ,	, , ,
'.'. '?'. '.'.	1,1,1,1,111	. "'". ':'.		':', '?',	'(', "'",
1_1 1 1 1 1 1	171 1,1 1	, 191, 1-1,	1 1 1 1	1,1' 1,1'	1,1' 171'
· = · , · · . · , · · . · ,	· · · · · · · · · · · · · · · · · · ·	, ' ( ' , ' ' , ' , ' , ' , ' , ' , ' ,	. , , , ,	· · · · · · · · · · · · · · · · · · ·	: ', ' ',
1 1 1 1 1 1 1 1 1 1	1 1 171 1.1	1 1 11 11	11 11 11 11 11		171 1 1
1.1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1		<i>'</i> .'.''			, ,
':', '"', '.',	'.', ':', '<'	, '.', ':',	':', '.',	':', '<',	'?', '.',
deprise a prise a consiste	1 1 1 1 17 1		ang ing manakan bandaran band	agai mani	
	. , . ,	, , , , ,	. , . ,	: , ,	, : ,
'!', '!', ':',	111 111 111		'?', ':',	"'", '!',	
1 1 1 1 1 1 1 1 1 1 1 1 1 1 1 1 1 1 1 1	. , . ,	, , , , ,		''	. , . ,
, , , ,	· • · , · • · , · • ·	, ':', ':',	. '!', ':',	·:', "'",	· · · , · · - · ,
171 1 1 1/1	THE THE STREET	1,1 171	'?', ':',	1,1 171	
· · · · · · · · · · · · · · · · · · ·	. , . ,	<i>'</i>		• , ,	· · · · · · · · · · · · · · · · · · ·
"'", '-', '.',	1?', '.', '''	, 171 , 171 ,		"", "",	'.', '.',
1,1, 1,1, 1,71,	1 1 1 1 1 1	´´ ´			1 1 191
	., ., .	, , - ,	· · , · · ,	:, .,	. , : ,
'?', '?', '!',	'<', "'", '.'			1 <u>-</u> 1, 111,	
		, , , , , , ,	' ' ' ' ' ' ' ' ' ' ' ' ' ' ' ' ' ' ' '	<b>''</b> .	
	'"', ''', '?'	, ' • ' , ' ' ' ,			
1 1 1 1 1 1 1 1 1	101 1 1 1 1		. , . ,	'!', '.',	"", ":",
. , . , . ,	. y	1,1 1,1	, . ,	'!', '.', '''	, , ,
	α, ., .	, ; , ; ,	'/', ':',	: , · , , , , , , , , , , , , , , , , ,	
'<', "'", "'",	1.1 1.1 1.1	, ':', ';', , ':', ';',	, . ,	; , ; , !!, !:!,	, , ,
1<1, "1", "1",	•	, ; , ; ,	'/', ':',	: , · , , , , , , , , , , , , , , , , ,	, , ,
111, 11, 11,	':', ':', '' '.', "'", '-'	, ; , ; , , ' , ' , ' , ' , , '?' , ' . ' ,	; ',', ';', ; ';', ';', ; ';', "'",	; , ; , '', ';', '!', '.',	, , , , , , , , , , , , , , , , , , ,
	1:1, 1:1, 1	, ; , ; , , , , , , , , , , , , , , , ,	' ' ' ' ' ' ' ' ' ' ' ' ' ' ' ' ' ' '	; , ; , !!, !:!,	, , ,
'?', '?', '!',	1:1, 1:1, 11 1:1, 111, 1-1	, : , : , ; , , ; , , , , , , , , , , ,		; , ; , '', ';', '!', '.',	, , , , , , , , , , , , , , , , , , ,
111, 11, 11,	1:1, 1:1, 1 1:1, 111, 1-1 1:1, 111, 111	, ; , ; , , , , , , , , , , , , , , , ,	; ',', ';', ; ';', ';', ; ';', "'",	; , ; , , ; , , ; ; , , ; ; , , ; ; , , ; ; , , ; ; , , ; ; , , ; ; , ; ; , ; ; ; , ; ; ; , ; ; ; , ; ; ; , ; ; ; , ; ; ; , ; ; ; , ; ; ; , ; ; ; , ; ; ; , ; ; ; , ; ; ; , ; ; ; , ; ; ; ; , ;	, , , , , , , , , , , , , , , , , , ,
',',',',',',',',',',',',',',',',',',',		, : , : , , , , , , , , , , , , , , , ,		; , ; , , ; , , ; ; , , ; ; , , ; ; , , ; ; , , ; ; , , ; ; , , ; ; , ; ; , ; ; ; , ; ; ; , ; ; ; , ; ; ; , ; ; ; , ; ; ; , ; ; ; , ; ; ; , ; ; ; , ; ; ; , ; ; ; , ; ; ; , ; ; ; , ; ; ; ; , ;	, , , , , , , , , , , , , , , , , , ,
','', '.', '.', '.', '.', '?', '?', '!', '!', '!', '!', '!', '!	1:1, 1:1, 1 1:1, 111, 1:1 1:1, 111, 1:1	, ; , ; , ; , , ; , , , , , , , , , , ,		; , ; , , ; , , ; ; , , ; ; , , ; ; , , ; ; , , ; ; , , ; ; , ; ; ; , ; ; ; , ; ; ; , ; ; ; , ; ; ; , ; ; ; , ; ; ; , ; ; ; , ; ; ; , ; ; ; , ;	· · · · · · · · · · · · · · · · · · ·
',', ',', ',',',',',',',',',',',',',','		, : , : , , , , , , , , , , , , , , , ,		; , , , , , , , , , , , , , , , , , , ,	· · · · · · · · · · · · · · · · · · ·
',', ',', ',',',',',',',',',',',',',','	':', ':', '' ':', """, """ ':', """, "!" ':', "!", ':'	, : , : , , , , , , , , , , , , , , , ,		; , ; , ; , ; ; , ; ; ; , ; ; ; , ; ; ; , ; ; ; , ;	' ' ' ' ' ' ' ' ' ' ' ' ' ' ' ' ' ' '
',',',',',',',',',',',',',',',',',',',	':', ':', '' ':', """, '!' ':', "!", '!' ':', '!', ':'	, ; , ; , ; , , ; , , , ; , , ; , , ; ; , ; , ; ; , , ; ; , ; , ; ; ; , ; ; ; , ; ; ; , ; ; ; , ; ; ; , ; ; ; , ; ; ; ; , ;	', ', ', ', ', ', ', ', ', ', ', ', ', '	; , ; , ; , ; ; , ; ; ; , ; ; ; , ; ; ; , ; ; ; , ;	' ' ' ' ' ' ' ' ' ' ' ' ' ' ' ' ' ' '
',',',',',',',',',',',',',',',',',',',	1:1, 1:1, 1:1, 1:1, 1:1, 1:1, 1:1, 1:1,	, ; , ; , ; , , ; , , ; , , ; , , ; ; , ; ; ; , ; ; ; , ; ; ; , ; ; ; , ; ; ; , ; ; ; , ; ; ; , ; ; ; , ; ; ; ; , ; ; ; ; , ;	', ', ', ', ', ', ', ', ', ', ', ', ', '	: , ; , ; , , ; ; , , ; ; , , ; ; , ; ; , ; ; , ; ; , ; ; , ; ; ; , ;	'.', '*', '.', '.', '.', '.', '.', '.', '.', '.', '.', '.', '.', '.',
',', ',', ',',',',',',',',',',',',',','	1:1, 1:1, 1:1, 1:1, 1:1, 1:1, 1:1, 1:1,	, ; , ; , ; , , ; , , , ; , , ; ; , ; ; ; , ; ; ; , ; ; ; , ; ; ; , ; ; ; , ; ; ; , ; ; ; , ; ; ; , ;	', ', ', ', ', ', ', ', ', ', ', ', ', '	; , ; , ; , , ; ; , , ; ; , , ; ; , , ; ; , , ; ; ; , ; ; ; , ; ; ; , ; ; , ; ; , ; ; , ; ; , ; ; , ; ; , ; ; , ; ; , ; ; , ; ; ; , ; ; ; , ; ; ; , ; ; ; , ; ; ; , ; ; ; , ; ; ; , ; ; ; , ; ; ; , ; ; ; ; , ; ; ; ; , ; ; ; ; , ; ; ; ; , ;	' ' ' ' ' ' ' ' ' ' ' ' ' ' ' ' ' ' '
',',',',',',',',',',',',',',',',',',',	1:1, 1:1, 1:1, 1:1, 1:1, 1:1, 1:1, 1:1,	, ; , ; , ; , , ; , , ; , , ; , , ; ; , ; ; ; , ; ; ; , ; ; ; , ; ; ; , ; ; ; , ; ; ; , ; ; ; , ; ; ; , ; ; ; ; , ; ; ; ; , ;	', ', ', ', ', ', ', ', ', ', ', ', ', '	: ', ':', '', ':', '', ':', '', '', '', '&', '', '', '', '',	'.', '*', '.', '.', '.', '.', '.', '.', '.', '.', '.', '.', '.', '.',
',', ',', ',',',',',',',',',',',',',','		, ; , ; , ; , , ; , , , ; , , ; ; , , , ; ; , , , ; ; , , , ; ; , , , ; ; , , , ; ; , , , ; ; , , , ; ; , , , ; ; , , , ; ; , , , ; ; , , , ; ; , , , ; ; , , , ; ; , , , ; ; , , , ; ; , , , ; ; , , , ; ; , , , ; ; , , , , ; ; , , , , ; ; , , , , ; ; , , , , ; ; , , , , , ; ; , , , , , ; ; ,	',',',',',',',',',',',',',',',',',',',	; , ; , , , , , , , , , , , , , , , , ,	' ' ' ' ' ' ' ' ' ' ' ' ' ' ' ' ' ' '
',',',',',',',',',',',',',',',',',',',		, ; , ; , ; , , ; , , ; , , ; ; , , ; ; , ; , ; ; , ; ; , ; ; , ; ; , ; ; , ; ; , ; ; , ; ; , ; ; , ; ; , ; , ; ; ; , ; ; ; , ; ; ; , ; ; ; , ; ; ; , ; ; ; , ; ; ; , ; ; ; , ; ; ; ; , ; ; ; ; ; , ;		; , ; , ; , ; , ; ; ; , ; ; ; , ; ; ; , ; ; ; ; , ;	'.', '*', '.', '.', '.', '.', '.', '.', '.', '.', '.', '.', '.', '.', '.', '.', '.', '.',
		, ; , ; , ; , , ; , , , ; , , ; ; , ; , ; ; ; , ; ; , ; ; , ; ; , ; ; , ; ; , ; ; , ; ; , ; ; ; , ; ; ; , ; ; ; , ; ; ; , ; ; ; , ; ; ; ; , ; ; ; ; , ; ; ; ; , ; ; ; ; , ;	',',',',',',',',',',',',',',',',',',',	; , ; , , , , , , , , , , , , , , , , ,	'.', '*', '.', '.', '.', '.', '.', '.', '.', '.', '.', '.', '.', '.',
1,1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1,		, ; , ; , ; , , ; , , ; , , ; ; , , ; ; , ; , ; ; , ; ; , ; ; , ; ; , ; ; , ; ; , ; ; , ; ; , ; ; , ; ; , ; , ; ; ; , ; ; ; , ; ; ; , ; ; ; , ; ; ; , ; ; ; , ; ; ; , ; ; ; , ; ; ; ; , ; ; ; ; ; , ;		; , , , , , , , , , , , , , , , , , , ,	' ' ' ' ' ' ' ' ' ' ' ' ' ' ' ' ' ' '
', ', ', ', ', ', ', ', ', ', ', ', ',	':', ':', '' ':', '!", '!! ':', '!', '!' ':', '!', '!' ':', '!', '!' '!', '!', '!'	, ; , ; , ; , , ; , , ; , , ; , , ; ; , ;		; , ; , ; , ; , ; ; , ; ; , ; ; , ; ; , ; ; , ; ; , ; ; , ; ; , ; ; , ; ; ; ; , ;	'.', '*', '.',
		, ; , ; , ; , , ; , , ; , , ; ; , , ; ; , ; ; , ; ; , ; ; , ; ; , ; ; , ; ; , ; ; , ; ; , ; ; ; , ; ; ; , ; ; ; , ; ; ; , ; ; ; , ; ; ; , ; ; ; ; , ;		; , ; , , , , , , , , , , , , , , , , ,	' ' ' ' ' ' ' ' ' ' ' ' ' ' ' ' ' ' '
', ', ', ', ', ', ', ', ', ', ', ', ',	1:1, 1:1, 1:1, 1:1, 1:1, 1:1, 1:1, 1:1,	, ; , ; , ; , , ; , , ; , , ; ; , ; , ; ; ; , ; ; ; , ; ; ; , ; ; ; ; , ; ; ; ; , ; ; ; ; ; ; ; ; ; , ;		; , ; , ; , ; ; , ; ; , ; ; , ; ; , ; ; , ; ; , ; ; , ; ; , ; ; , ; ; ; , ; ; ; , ;	'.', '*', '.',
	':', ':', '' ':', '!", '!! ':', '!', '!' ':', '!', '!' ':', '!', '!' '!', '!', '!'	, ; , ; , ; , , ; , , ; , , ; ; , , ; ; , ; ; , ; ; , ; ; , ; ; , ; ; , ; ; , ; ; , ; ; , ; ; ; , ; ; ; , ; ; ; , ; ; ; , ; ; ; , ; ; ; , ; ; ; ; , ;		; , ; , , , , , , , , , , , , , , , , ,	' ' ' ' ' ' ' ' ' ' ' ' ' ' ' ' ' ' '
', ', ', ', ', ', ', ', ', ', ', ', ',	1:1, 1:1, 1:1, 1:1, 1:1, 1:1, 1:1, 1:1,	, ; , ; , ; , , ; , , ; , , ; ; , ; , ; ; , ; , ; , ; ; , ; , ; ; , ; , ; ; , ; , ; ; , ; , ; ; , ; , ; ; , ;		; , ; , ; , ; ; , ; ; , ; ; , ; ; , ; ; , ; ; , ; ; , ; ; , ; ; , ; ; ; , ; ; ; , ;	' ' ' ' ' ' ' ' ' ' ' ' ' ' ' ' ' ' '
' ' ' ' ' ' ' ' ' ' ' ' ' ' ' ' ' ' '	':', ':', '' ':', '!', '!' ':', '!', '!' ':', '!', '!' ':', '!', '!' '!', '!', '!'			; , , , , , , , , , , , , , , , , , , ,	' ' ' ' ' ' ' ' ' ' ' ' ' ' ' ' ' ' '
	':', ':', '' ':', '!', '!' ':', '!', '!' ':', '!', '!' ':', '!', '!' '!', '!', '!' '!', '!', '!' '!', '!',			; , ; , ; , ; ; , ; ; , ; ; , ; ; , ; ; , ; ; , ; ; , ; ; , ; ; ; , ;	' ' ' ' ' ' ' ' ' ' ' ' ' ' ' ' ' ' '

<pre>: ', i, ', ', ', ', ', ', ', ', ', ', ', ', ',</pre>
<pre>'.', ':', '(', ':', "'", "'", '?', '.', "'", '.', '!", '!", '!", '!", '!", '!", '!", '!</pre>
<pre>'.', '!', '!', '?', '?', '!', '-', '!', "'", "'", '-', '-', '?', '!', '£', ''', '!', '!', '!', '!', '!'', '!'', '!'', '!'', "'", ''', '!', '?', '!', '!', '!', '!', '!'</pre>
'£', ''', '!', ':', '.', "'", '.', '!', '.', '.', '.', '.', '.', "'", ''', """, ''', """, ''', '!''', '!'''', '!''', '!''', '!'''', '!'''', '!'''', '!'''', '!'''', '!''''''''
""", ''', '/', '?', '.', '.', '.', '.', '.', '.', '.
<pre> '!', '!', '!', '!', '!', '!', '!', '!',</pre>
<pre> '.', "'", '.', '.', '.', "'", '.', '.',</pre>
':', '.', '.', '-', "'", ':', '.', '.', '?', "'", '?', '!', '?', '!', '?', '!', '!', '!'
; , , , , , , - , , ; , , , , ; , ; , , ; , ;
''', '.', '!', '', '.', '!", '?', '.', '!', '!', '!', '!',
,,,,,,,,,,
':', ':', '.', '!', ''', '.', ':', "'", '-', '-', '-', '.', '.', ''', '.',
'.', '?', '.', ':', ':', '!', '!', '!', '.', ':', ':', "'", "'",
"'", '£', "'", '-', '!', "'", ':', '!', '!', ''', '.', ':', '"', ':',
''', '.', '?', '!', '!', '!', '!', '!', '!', '!
':', '.', '.', '!', ''', '.', '.', ':', ''', '/', ':', '.', ''',
'!', '!', '.', '?', ''', "'", '!', ''', '.', "'", '.', '!', '!', '-',
'!', '-', '-', '.', "'", ':', '.', "'", ':', ':', '?', ':', ':', '-',
1:1, 1/1, 1?1, 1:1, 1-1, 1111, 1-1, 1.1, 1111, 1.1, 1.1,
'?', '.', ':', ':', '?', '.', '.', '-', ':', '.', '.', '.', '.',
'?', ':', "'", ':', ''', '!', ':', '.', '', '', ':', ':', '-', ':',
"", "", '/', ' ' ', ' ', ' ', ' ', ' ',
. , . , . , . , . , . , . , . , . , . ,
'?', '.', '.', '!', '-', '?', '.', '?', '.', "'", ".', '.',
'.', '!', '(', ':', '.', ':', ':', '!', '.', ':', ':', ':', '-', '!',
"'", '!', '!', ':', "'", "'", '.', '<', '.', ':', '.', ':', '(',
1:1, 1:1, 1:1, 1:1, 1:1, 1:1, 1:1, 1:1,
'<', '.', '.', '.', '.', ':', ':', "'", '?', ':', ':', ':',
':', ':', "'", '.', ':', '.', ':', '(', "'", ''', ':', '/', ':',
'.', ':', "'", "'", '!', ':', "'", '.', "'", '.', '!', ':', ':', ':',
·?', ·.', ·.', ·, ·, ·-', ·?', "'", ·.', ·, ·, ·, ·, ·!', ·!', ·''', "'",
· · · · · · · · · · · · · · · · · · ·
'(', '.', '!', '.', '?', ',', '?', "'", ',', '.', '!', ',', '.',
$\left(\begin{array}{cccccccccccccccccccccccccccccccccccc$
,,,,,,,,,,
···, ····, ····, ···, ···, ····, ····, ··

1 1 1 1 11 11 1 1 1 1 1 1 1 1 1 1 1 1 1	/
	'.', '/', "'", "'", '?', '.', ',',
	17   1   1   1   17   17   17
"", ', ', ', "", ", ', ', ', ', ', ', ', ', ', ', ', ', ',	1,,,,,,,,,,,,,,,,,,,,,,,,,,,,,,,,,,,,,,
	'-', "'", ''', '.', "'", '&', ''',
1 1 11 1/1 1/1 1/1 1/1 1/1	וןו ולו ולו ולו וווו ויו ולו
	1 1 1 1 1 1 1 1 1 1 1 1 1 1 1 1 1 1 1 1
1?1, 1.1, 1111, 1111, 1, 1, 1, 1, 1, 1, 1, 1, 1	"", ', ', ', ", ', ', ', ', ', ', ', ', ', ', ', ', ',
	, , - , : , , , , , , ,
1 1 1111 1/1 1/1 1/1 1 1 1 1	11
1?1, 1?1, "1", "1", 1.1, 1.1, "1",	''', '?', "'", '?', '?', ',', "'",
1?1, 1?1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1	
	, , , , , , , , , , , , , , , , , , , ,
1,	
1 1 1 1 171 171 1 1 1 1 1 1 1	1/1 1 1 11 11 1 1 1 1 1 1 1 1
	\
'.'. "'". '.'. '.'. '-'. '"'. '?'.	· . · . · . · . · . · . · . · . · . · .
, . , . , . , . , . ,	
111 1 1 111 171 1111 1111 1	
, . , . , . , . , . , . , . ,	
'?', '!', "'", ':', '.', '?', '.',	'?', '?', '.', '.', '.', '!', "'",
, , , , , , , , , , , , , , , , , , , ,	
	""", 17", 1,1, 1,1, """, """, "1", "1",
	1 1 1 1 1 1 1 1 1 1 1 1 1 1 1 1 1 1 1 1
111, 11, 111, 111, 111, 121,	···, ·!·, ···, ·?·, ···, "·", ·:·,
1.1, "1", 1?1, 1/1, 1.1, "1", 1:1,	i i mim ili mim ili ili ili ili
"'", '?', '.', '?', '.', '.', '.',	'.', '!', ':', '.', '!', '?', "'",
	"'", '?', "'", '?', "'", '?', '?',
וו ויַו ווו וווו ווו וין וי	'?', '?', '?', '.', '!', '!', '?',
· , - , · , · , · , · , · , · , · , · ,	
1.1, "1", '?', ':', '.', '.', "1",	'!', "'", "'", '!', "'", "'", '?',
ווו וי וי וי וווי וווי וי וווי וי וווי	
	, , , , , , , ,
1 1 1 1 1 1 1 1 1 1 1 1 1 1 1 1 1 1 1 1	"" " " " " " " " " " " " " " " " " " " "
111   1   1   10,1   1   17   11   11	
"", ", ", ", ", ", ", ", ", ", ", ", ",	
	, , , , , , , , , , , , , , , , , , , ,
1 . , . ? , . , . , . , . , . , . , . , .	
· · · · · · · · · · · · · · · · · · ·	, , , , , , , , , , , , , , , , , , , ,
1/1 1/1 1/1 1/1 1/1 1/1 1/1	1.1, 1:1, "1", 1.1, 1?1, 1:1, "1",
	., ., ., ., ., ., ., .,
	, , , , , , , , , , , , , , , , , , , ,
171   111   1   1   1   1   1   1   1	
	, , , , , , , , , , , , , , , , , , , ,
"'", '?', '?', "'", '.', '?', '.',	1.1, "1", 1.1, 1.1, 1.1, 1.1, 1.21,
	., :, , , -, :, :,
	1 1 1111 1111 1 1 1 1 1 1 1 1 1 1 1 1 1
, , , , , , , , , , , , , , , , , , , ,	
-, ", ", ", ", ", ", ", ", ", ", ", ", ",	"", "", ", ", ", ", ", ", ", ", ", ", ",
· , · , <sup>π</sup> , · , · , · , ,	
1 1 1111 121 1111 121 121 1_1	
'(', '+', '.', '?', '.', '#', '!',	
171 1111 1/1 1 1 1 1 111 1111	
	., , , , + , , , , ,
1.1, 1.1, "1", 1.1, "+", 1.1, ":",	1.1, 1-1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1
"'", '?', "'", '.', "'", '!', "'",	., ., ., ., 6, !, >,
	THE HER $1_{\perp}$ E I I III HEH HEH
1 1 1 1 11 11 1 1 1 1 1 1 1 1 1 1 1 1 1	1* 1 1 1 1 1 1 1 1 1 1 1 1 1 1 1 1 1 1
. , . , . , . , . , . , , ,	", , , , , , , , , , , , , , , , , , ,
	, _ , _ ,
	", , , , , , , , , , , , , , , , , , ,

```
11 1 11
                                            11 1 11
                                                              \Pi = \Pi
                  11 1 11
                                                                       11 1 11
                                                                                11 1 11
                                   11 1 11
                                                              11 1 11
                                                                                11 1 11
                 11 1 11
                 11 1 11
                                                                                11 1 11
                                                              11 1 11
                                                                                         1 * 1
        11 1 11
                                                              11 1 11
        11 1 11
                                                              171
                 11 1 11
                                   11 1 11
                                            11 1 11
                                                              11 1 11
                         """
                                            11 1 11
                          11 11 11
                                            11 11 11
                                                                       11 11 11
                          \Pi \Pi \Pi
                                            'i',
11 1 11
                '.',
'.',
                                                     11 1 11
                                            11 1 11
                          11 1 11
                                                     11 1 11
                                                                       . į .
                 11 1 11
                                   11 1 11
                                                                       11 1 11
                                   11 1 11
                                                                       11 1 11
                          '?'
                 .., "."
11 1 11
                                                                                11 1 11
                      , """
        11 1 11
                                                     1 11 1
                                                              11 1 11
                                                              \Pi = \Pi
                                                                       11 1 11
                                                                                11 1 11
                                                     11 1 11
                                                              171
                                                                                         '*', '!',
                                           11 1 11
Total items found: 13 ['88', '88', '18', '18', '18', '18', '18', '88',
'18', '18', '18', '18', '18']
['88', '88', '18', '18', '18', '18', '18', '88', '18', '18', '18', '18', '18', '18']
```

Remove these patterns

```
# Remove user handles
df.replace(r'@[\w]*', '', regex=True, inplace=True)
```

```
# Remove hashtags
df.replace(r'#[\w]*', '', regex=True, inplace=True)
# Remove URLs
df.replace(r'https?://[A-Za-z0-9./]+', '', regex=True, inplace=True)
# Remove punctuations
df.replace(r'[^\w\s]', '', regex=True, inplace=True)
# Remove digits
df.replace(r'\d+', '', regex=True, inplace=True)
# Replace underscores with spaces
df.replace(r'_', ' ', regex=True, inplace=True)
# show random 5 rows
df.sample(5, random state=1)
# print row 663 to see the result
print(df['comment'].iloc[663])
england is tnot aawys the best but atleast they triedsmiling face with
tearsmiling face with tearsmiling face with tearsmiling face with
tearloudly crying faceloudly crying faceloudly crying face
```

### Decapitalize

```
df["comment"] = df["comment"].str.lower()

# print 662 row
print(df["comment"].iloc[663])

england is tnot aawys the best but atleast they triedsmiling face with tearsmiling face with tearsmiling face with tearsmiling face with tearloudly crying faceloudly crying face
```

#### Tokenize

```
# Convert comment to strings
df['comment'] = df['comment'].apply(str)

# Tokenize using Tokenizer
tokenizer = WordPunctTokenizer()
df['comment'] = df['comment'].apply(tokenizer.tokenize)

# Show random 5 rows
df.sample(5, random_state=2)
```

```
comment
                                                            source
label
2172
      [good, luck, to, both, although, im, personall...
                                                            reddit
3003
               [croatia, deserve, that, goal, and, more]
                                                            reddit
1711
                                        [forza, bologna]
                                                           youtube
2622
                 [cam, on, ingerland, score, sam, gaos]
                                                            reddit
3082
                                              [own, goal]
                                                            reddit
```

## Remove Stopwords

```
#remove stopwords
stopwords = stopwords.words('english')
df['comment'] = df['comment'].apply(lambda x: [item for item in x if
item not in stopwords])
#show random 5 rows
df.sample(5, random state=1)
                                                comment
                                                          source
label
1135
      [cant, believe, icardi, missed, penalty, score...
                                                         voutube
      [congratulations, morocco, win, th, world, mea... youtube
1857
2481
      [another, long, past, due, debt, paid, footbal... reddit
988
      [inter, arsenal, surprise, package, seasons, c... youtube
102
       [little, stupid, bitch, dont, fuck, yoooooouuuu]
                                                          kaggle
1
```

### Remove special characters

```
def rem_nonalpha(text):
    '''Function to remove the non-alphanumeric characters from the
text'''
    text = [word for word in text if word.isalpha()]
    return text

# Apply the function to the 'comment' column
df['comment'] = df['comment'].apply(rem_nonalpha)
```

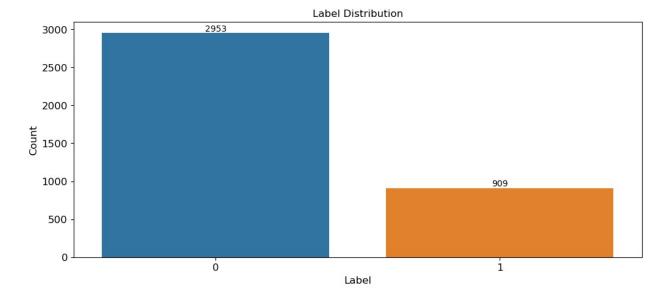
Remove digits

```
# Remove digits from each comment in the DataFrame
def remove_digits(comment):
    return [item for item in comment if not item.isdigit()]

# Apply the function to the 'comment' column
df['comment'] = df['comment'].apply(remove_digits)
```

#### Check for data balance

```
sns.countplot(x='label', data=df)
plt.title('Label Distribution')
plt.xlabel('Label')
plt.ylabel('Count')
for index, value in df['label'].value_counts().items():
    plt.text(index, value, str(value), ha = 'center', va = 'bottom')
plt.show()
```



## Explore most frequently used words

```
from collections import Counter
results = Counter()
df['comment'].apply(results.update)
#print the top 10 most common terms in the tweet
print(results.most_common(10))

[('like', 308), ('game', 253), ('tears', 253), ('team', 235), ('face', 207), ('bitch', 188), ('england', 177), ('dont', 170), ('one', 161), ('im', 154)]
```

## Predictive Modelling

Data formatting and predictive modelling

```
# check for null values
print(f"Null values: {df.isnull().sum()}")
Null values: comment 0
source
label
           0
dtype: int64
# join comment back together
df["comment"] = df["comment"].apply(lambda x: ' '.join(x))
# show random 5 rows
df.sample(5, random state=1)
                                                comment
                                                          source
label
1135 cant believe icardi missed penalty scored norm... youtube
1857 congratulations morocco win th world mean real... youtube
2481 another long past due debt paid football manci... reddit
     inter arsenal surprise package seasons champio... youtube
988
              little stupid bitch dont fuck yooooouuuu
102
                                                          kaggle
#split data into input X and output y
X = df['comment']
y = df['label']
# split the data into training and testing sets
from sklearn.model selection import train test split
X_train, X_test, y_train, y_test = train_test_split(X, y,
test size=0.2, random state=1)
print(X train.shape, X test.shape, y train.shape, y test.shape)
(3089,) (773,) (3089,) (773,)
# use TfidfVectorizer to convert the raw documents into feature matrix
from sklearn.feature extraction.text import TfidfVectorizer
vectorizer = TfidfVectorizer(max features=5000)
X train = vectorizer.fit transform(X train).todense()
X test = vectorizer.transform(X test).todense()
print(X train.shape, X test.shape)
(3089, 5000) (773, 5000)
```

## Model building: Ordinary logistics regression

```
import numpy as np
# ordinary logistic regression
from sklearn.linear_model import LogisticRegression

# instantiate the model (using the default parameters)
logreg = LogisticRegression()
logreg.fit(np.asarray(X_train), np.asarray(y_train))
train_predictions = logreg.predict(np.asarray(X_train))
test_predictions = logreg.predict(np.asarray(X_test))
```

#### Model evaluation

```
from sklearn.metrics import accuracy score, classification report,
confusion matrix, fl score
# accuracy score
print(f"Train Accuracy: {accuracy_score(y_train, train_predictions)}")
print(f"Test Accuracy: {accuracy score(y test, test predictions)}")
Train Accuracy: 0.8883133700226611
Test Accuracy: 0.851228978007762
# classification report
print("Train Classification Report")
print(classification report(y train, train predictions))
print("Test Classification Report")
print(classification report(y test, test predictions))
Train Classification Report
              precision
                            recall f1-score
                                               support
                   0.87
                              1.00
                                        0.93
                                                   2371
           1
                   0.98
                              0.53
                                        0.69
                                                   718
                                        0.89
                                                   3089
    accuracy
   macro avg
                   0.93
                              0.76
                                        0.81
                                                   3089
                   0.90
                              0.89
                                        0.88
weighted avg
                                                   3089
Test Classification Report
              precision
                            recall f1-score
                                               support
           0
                   0.84
                              0.99
                                        0.91
                                                    582
           1
                   0.92
                              0.43
                                        0.59
                                                    191
                                        0.85
                                                    773
    accuracy
                   0.88
                              0.71
                                        0.75
                                                    773
   macro avg
weighted avg
                   0.86
                              0.85
                                        0.83
                                                    773
```

```
# define the weight of the classes using inverse ratio
weights = \{0: 1.0, 1:13.0\}
#instantiate the logistic regression model and account for the weights
to be applied for model coefficients update magnitude
logreg = LogisticRegression(class weight=weights)
#fit the model
logreg.fit(np.asarray(X train), np.asarray(y train))
train predictions = logreg.predict(np.asarray(X_train))
test predictions = logreg.predict(np.asarray(X test))
#classification report
print("Train Classification Report")
print(classification report(y train, train predictions))
print("Test Classification Report")
print(classification_report(y_test, test predictions))
Train Classification Report
              precision
                           recall f1-score
                                               support
           0
                   1.00
                              0.87
                                        0.93
                                                  2371
           1
                   0.69
                              1.00
                                        0.82
                                                   718
                                        0.90
                                                  3089
    accuracy
   macro avq
                   0.85
                             0.93
                                        0.87
                                                  3089
                   0.93
                              0.90
                                        0.90
                                                  3089
weighted avg
Test Classification Report
              precision
                           recall f1-score
                                               support
                   0.93
                             0.74
                                        0.82
                                                   582
           1
                   0.51
                              0.82
                                        0.63
                                                   191
    accuracy
                                        0.76
                                                   773
                                        0.73
                   0.72
                             0.78
                                                   773
   macro avq
                                        0.78
weighted avg
                   0.82
                              0.76
                                                   773
```

## Regularization and Hyperparameter Tuning

```
# regularization and hyperparameter tuning
'''from sklearn.model_selection import GridSearchCV
# define the grid
param_grid = {'C': [0.001, 0.01, 0.1, 1, 10, 100, 1000]}
# instantiate the model
logreg = LogisticRegression(class_weight=weights)
# instantiate the grid search model
grid_search = GridSearchCV(logreg, param_grid, cv=5)
```

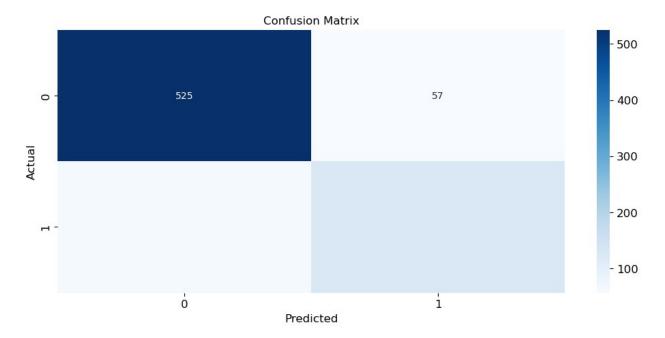
```
# fit the grid search to the data
grid_search.fit(np.asarray(X_train), np.asarray(y_train))
# print the best parameters
print(f"Best Parameters: {grid_search.best_params_}")'''

'# regularization and hyperparameter tuning\nfrom
sklearn.model_selection import GridSearchCV\n# define the grid\nparam_grid = {\'C\': [0.001, 0.01, 0.1, 1, 10, 100, 1000]}\n#
instantiate the model\nlogreg =
LogisticRegression(class_weight=weights)\n# instantiate the grid
search model\ngrid_search = GridSearchCV(logreg, param_grid, cv=5)\n#
fit the grid search to the data\ngrid_search.fit(np.asarray(X_train),
np.asarray(y_train))\n# print the best parameters\nprint(f"Best
Parameters: {grid_search.best_params_}")'
```

Fine tuned Model with Balanced Class Weights

```
'''# retrieve the best model
best model = result.best estimator
print(best model)
                                          Traceback (most recent call
NameError
last)
Cell In[28], line 2
      1 # retrieve the best model
----> 2 best model = result.best estimator
     3 print(best model)
NameError: name 'result' is not defined
#instantiate the best model
logreg = LogisticRegression(C=10, class weight={0: 1.0, 1: 13},
penalty='l1', solver='liblinear')
logreq.fit(np.asarray(X train), np.asarray(y train)) # Fit the
logistic regression model
train predictions = logreg.predict(np.asarray(X train))
test predictions = logreg.predict(np.asarray(X test))
# Classification report
print("Train Classification Report")
print(classification report(y train, train predictions))
print("Test Classification Report")
print(classification report(y test, test predictions))
# Confusion matrix
print("Train Confusion Matrix")
```

```
print(confusion matrix(y train, np.asarray(train predictions)))
print("Test Confusion Matrix")
print(confusion matrix(y test, np.asarray(test predictions)))
Train Classification Report
              precision
                            recall f1-score
                                                support
           0
                    1.00
                              1.00
                                        1.00
                                                   2371
           1
                    0.99
                              1.00
                                        1.00
                                                    718
                                        1.00
                                                   3089
    accuracy
                              1.00
   macro avg
                    1.00
                                        1.00
                                                   3089
                                        1.00
                              1.00
                                                   3089
weighted avg
                    1.00
Test Classification Report
              precision
                            recall f1-score
                                               support
           0
                    0.89
                              0.90
                                        0.90
                                                    582
           1
                    0.69
                              0.65
                                        0.67
                                                    191
                                        0.84
                                                    773
    accuracy
                    0.79
                              0.78
                                        0.78
   macro avg
                                                    773
weighted avg
                    0.84
                              0.84
                                        0.84
                                                    773
Train Confusion Matrix
[[2365]
          61
[ 1 717]]
Test Confusion Matrix
[[525 57]
[ 66 125]]
# confusion matrix as a heatmap
conf matrix = confusion matrix(y test, test predictions)
sns.heatmap(conf_matrix, annot=True, fmt='d', cmap='Blues')
plt.xlabel('Predicted')
plt.vlabel('Actual')
plt.title('Confusion Matrix')
plt.show()
```



## Export model

```
#export model
import joblib
joblib.dump(logreg, 'logreg_model.pkl')
joblib.dump(vectorizer, 'vectorizer.pkl')
['vectorizer.pkl']
```

## make prediction with model

```
# make predictions on a new dataframes column "comment"
# make predictions on a new dataframes column "comments"
new data = pd.read excel(r'C:\VSCode\NLP4B Football\Own model\model
creation\youtube cleaned for label NEW.xlsx')
new data["comments"] = new data["comments"].astype(str)
new_data["comments"] =
new data["comments"].apply(convert_emojis_to_word)
new_data.replace(r'@[\w]*', '', regex=True, inplace=True)
new_data.replace(r'#[\w]*', '', regex=True, inplace=True)
new data.replace(r'https?://[A-Za-z0-9./]+', '', regex=True,
inplace=True)
new_data.replace(r'[^\w\s]', '', regex=True, inplace=True)
new_data.replace(r'\d+', '', regex=True, inplace=True)
new_data.replace(r'_', '', regex=True, inplace=True)
new data['comments'] = new data['comments'].apply(tokenizer.tokenize)
new data['comments'] = new data['comments'].apply(lambda x: [item for
item in x if item not in stopwords])
new_data['comments'] = new_data['comments'].apply(rem_nonalpha)
```

```
new_data['comments'] = new_data['comments'].apply(remove_digits)
new_data["comments"] = new_data["comments"].apply(lambda x: '
'.join(x))
new_data["comments"] = new_data["comments"].astype(str)
new_data_predictions =
logreg.predict(np.asarray(vectorizer.transform(new_data["comments"]).t
odense()))
new_data["label"] = new_data_predictions
new_data.to_excel(r'C:\VSCode\NLP4B_Football\0wn_model\model creation\
pred_youtube_cleaned_for_label.xlsx', index=False)
```

#### evaluate newdata

```
#copy dataframe
football offense = new data.copy()
#output number of label 1 and 0 comments
print(football offense['label'].value counts())
#find the percentage of label 1 comments
print(football offense['label'].value counts(normalize=True))
# find percentage of label 1 comments where type is international
print(football offense[football offense['label'] == 1]
['type'].value counts(normalize=True))
percentages = football offense.groupby('type')['label'].mean() * 100
# Print the percentages
for index, value in percentages.items():
    print(f"{index}: {value:.2f}%")
# compare both types numerically and visually
print(football offense[football offense['label'] == 1]
['type'].value counts())
sns.countplot(x='type',
data=football offense[football offense['label'] == 1])
plt.title('Type Distribution of Label 1 Comments')
plt.xlabel('Type')
plt.ylabel('Count')
plt.show()
# plot percentages of label 1 out of all comments for each type
sns.barplot(x=football offense['type'], y=football offense['label'],
```

```
estimator=lambda x: sum(x==1)*100.0/len(x))
plt.title('Percentage of Label 1 Comments for Each Type')
plt.xlabel('Type')
plt.ylabel('Percentage')
plt.show()
label
0
     1633
      140
Name: count, dtype: int64
label
0
     0.921038
1
     0.078962
Name: proportion, dtype: float64
type
league
                 0.578571
                 0.421429
international
Name: proportion, dtype: float64
international: 5.67%
league: 11.05%
type
league
                 81
                 59
international
Name: count, dtype: int64
```

